



이 채린 (CHAELYN LEE)

LLM/Agent Technical Strategy Researcher

010-3227-1747 mylynchae@gmail.com Seongnam, South Korea

PROFILE

LLM inference·RAG·fine-tuning 및 AI 가속기 기반 성능 분석을 수행해 온 NLP/LLM 연구자. 학부 NLP 응용에서 시작해 석사 과정에서 LLM 효율 파인튜닝, RAG 응용, 금융 보안 NLP를 연구함. 현재 vLLM 기반 LLM 서빙 및 이기종 가속기 기반 추론 최적화를 수행하며, serving cost·latency 최적화를 중점적으로 수행 중. ACM TIST Q1, NAACL 등 Top-tier 포함 주저자 논문 7편 게재. 향후 금융 도메인 특화 LLM/Agent 구축, 대화형 AI 서비스의 multi-user serving 인프라 설계 등 증권 AI 에이전트 고도화 영역으로 확장하고자 함.

EXPERIENCE

EMPLOYMENT

2024.11 - Present
한국전자기술연구원 (KETI)
SoC플랫폼연구센터

EDUCATION

2022.09 - 2024.08
중앙대학교 일반대학원
AI학과 석사과정 졸업

2018.03 - 2022.02
상명대학교
스마트정보통신공학과 졸업

SKILLS

- LLM/RAG
- Hugging Face, vLLM, LoRA/PEFT, RAG, Prompting, LLM Evaluation
- LLM Systems
- Inference profiling, CUDA, TTFT/TBT analysis, serving, throughput optimization,
- Data/ML
- PyTorch, TensorFlow, Scikit-learn, Pandas, SQL
- Programming
- Python, C, Linux

LICENSES

- OPIC IM
- SQLD

- 한국전자기술연구원
- vLLM 기반 multi-user LLM serving 성능 분석 및 최적화 체계 구축
 - 이기종 가속기 환경에서 vLLM 기반 LLM 추론 성능 분석 체계(profiling workflow·성능 DB) 구축
 - Prefill/Decode 분리 할당 서빙 전략 제안 → SLO 99% 충족 및 단일 가속기 대비 RPS 약 2배 향상
 - ICTC 2025, "Latency-Aware Optimization Strategies for Efficient LLMs Serving on Heterogeneous Accelerators"
- LLM Inference Engine 종합 Survey
 - 25개 주요 LLM 추론 엔진을 시스템 스택 전반에서 체계화
 - Throughput·latency·serving 등 production 관점에서 비교 분석
 - LLM 서빙 인프라 설계 시 활용 가능한 엔진 선택 기준 제시
 - ACM TIST 2026, "A Survey on Inference Engines for Large Language Models: Perspectives on Optimization and Efficiency"
- 데이터센터 워크로드/시스템 분석 시뮬레이션 플랫폼 개발
 - SST-QEMU 연동으로 이기종 환경 AI 워크로드 고속/고정확도 분석 full-system simulator 기획·개발
- 이기종 가속기 기반 LLM 추론의 수치 오차 허용 한도 정량화
 - 메모리 중심 가속기가 LLM 추론 품질에 미치는 영향을 정량화하기 위한 Error Model 제안
 - IEIE 2026, "An Error Model for Characterizing Numerical Error Tolerance in Heterogeneous Accelerator-Based LLM Inference" (to appear)
- 중양대학교
- LoRA(Low-Rank Adaptation) 기반 LLM 효율 파인튜닝
 - LoRA 기반 PEFT 기법을 통해 Aspect-Based Sentiment Analysis 도메인에 특화된 모델 제안
 - GPT-2 기준 학습 파라미터 수를 원본의 0.05% 축소, 학습 시간 약 35% 단축
 - ICCE 2024, "An Efficient Fine-Tuning of Generative Language Model for ABSA"
 - Electronics Letters 2025, "Fast Fine-Tuning Large Language Models for ABSA"
- LLM 입력 Robustness — BitAbuse 데이터셋 및 복원 모델 구축
 - 비트코인 스캠·피싱 등 금융 사기 텍스트에서 추출한 시각적 교란 텍스트 데이터셋 구축 (약 32만 문장)
 - Character BERT 기반 텍스트 복원 모델 제안 → 약 96% 복원 정확도 달성
 - NAACL 2025, "BitAbuse: A Dataset of Visually Perturbed Texts for Defending Phishing Attacks"
- 사이버보안 AI 모델을 위한 Q&A 데이터셋 구축
 - 보안 도메인 지식 검색/RAG 시스템에 필요한 질의응답 데이터 구조 설계
- 생성형 AI 기반 동요 가사 생성 및 품질 평가 연구
 - RAG 기반 생성 파이프라인 설계 및 구현
 - Passage Retrieval, LLM few-shot prompting, 외부 지식 기반 생성 흐름 구성
- 상명대학교
- 학부 졸업 프로젝트: NLP 기반 스팸문자 감지 앱
 - RNN 기반 스팸 문자 감지 모바일 앱 end-to-end 개발 경험, 이후 석사 BitAbuse 연구로 확장

PUBLICATIONS

Major Publications

- **C. Lee**, S. Park, S. Jeon, B. S. Kim, J. Lee, "A Survey on Inference Engines for Large Language Models: Perspectives on Optimization and Efficiency" ACM Transactions on Intelligent Systems and Technology, Just Accepted, March 2026. <https://doi.org/10.1145/3803798>
- **C. Lee**, H. Lee, Y. Lee, J. Lee, "BitAbuse: A Dataset of Visually Perturbed Texts for Defending Phishing Attacks" 2025 Annual Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics (NAACL 2025), New Mexico, USA, 29 April – 4 May 2025.

Journal (SCIE)

- **C. Lee**, J. Lee, "Fast Fine-Tuning Large Language Models for Aspect-Based Sentiment Analysis" Electronics Letters, 61(1):e70411, September 2025.

Conferences

- **C. Lee**, S. Jeon, "Latency-Aware Optimization Strategies for Efficient LLMs Serving on Heterogeneous Accelerators" 16th International Conference on Information and Communication Technology Convergence (ICTC 2025), Jeju, Korea, 2025, pp. 1980–1982.
- **C. Lee**, J. Lee, S. Jeon, "An Error Model for Characterizing Numerical Error Tolerance in Heterogeneous Accelerator-Based LLM Inference," 대한전자공학회 하계종합학술대회 (IEIE 2026), Jeju, Korea, 2026. (to appear)
- **C. Lee**, H. Lee, K. Kim, S. Kim, J. Lee, "An Efficient Fine-Tuning of Generative Language Model for Aspect-Based Sentiment Analysis" The 42nd IEEE International Conference on Consumer Electronics (ICCE 2024), Las Vegas, USA, 5–8 January 2024.
- K. Kim, **C. Lee**, J. Lee, "Improving Dense Passage Retrieval using Weighted Passage Perturbation" 대한전자공학회 하계종합학술대회 (IEIE 2024), 61(1):2765–2768, Jeju, Korea, 26–28 June 2024.
- **C. Lee**, J. Lee, "A Crux on Current Neural Collaborative Filtering Methods" International Conference on Electronics, Information, and Communication (ICEIC 2023), Singapore, 5–7 February 2023.